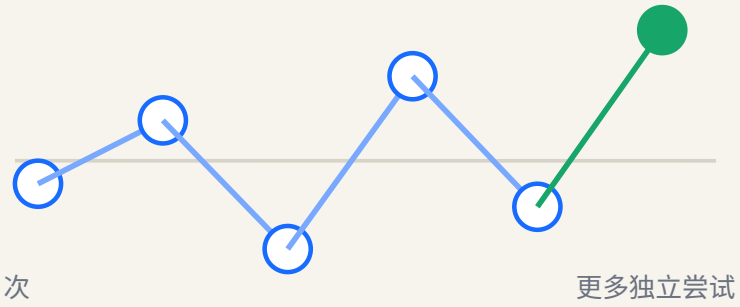
论文分享 • arXiv:2407.21787

Large Language Monkeys

Scaling Inference Compute with Repeated Sampling



重复采样如何把推理算力变成可预测的性能增长

正确答案能被验证，弱模型也能被重复采样放大

Bradley Brown • Jordan Juravsky • Ryan Ehrlich • Ronald Clark • Quoc V. Le • Christopher Ré • Azalia Mirhoseini

Stanford • Oxford • Google DeepMind

研究问题

推理算力的另一条扩展轴

训练侧

更大的模型、更多数据、更长训练

缩放律让“增加训练算力”成为可预测路径

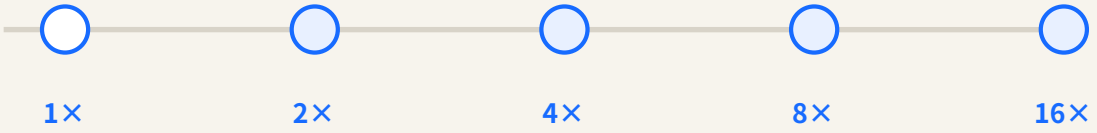
推理侧

大多数系统只让模型尝试一次

思维链让单次尝试更长，却没有增加独立解法的数量。

把样本数 k 作为推理算力

同一道题生成多个相互独立的候选解

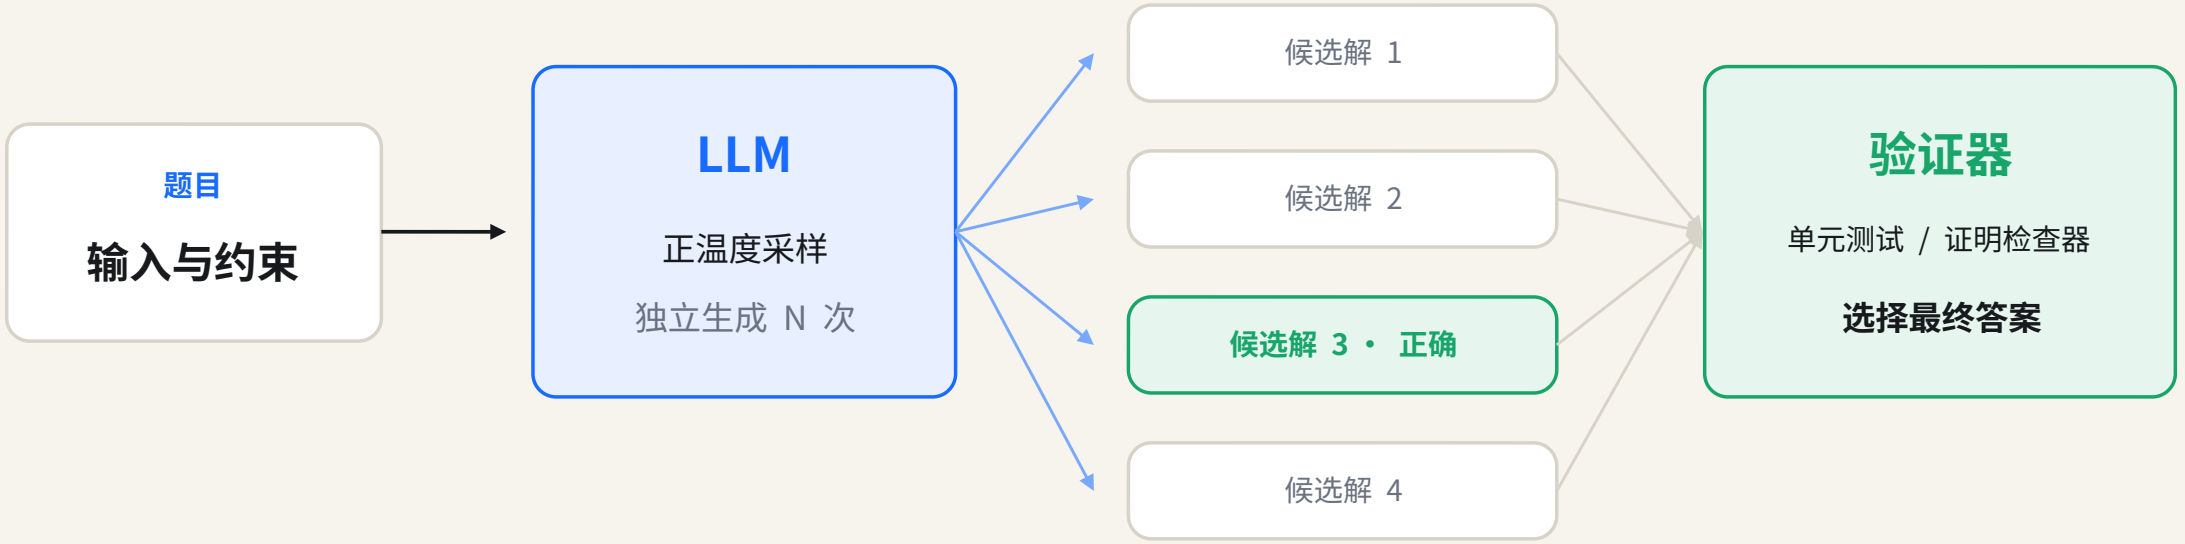


研究问题

性能会不会随采样次数稳定增长?

方法

重复采样与验证



Coverage N 个样本中，至少一个正确的题目比例

Precision 能否从候选集合里找出正确解

本文只研究可判定对错的 pass/fail 任务：自动验证器可把 coverage 直接转化为成绩；否则 coverage 只是上限。

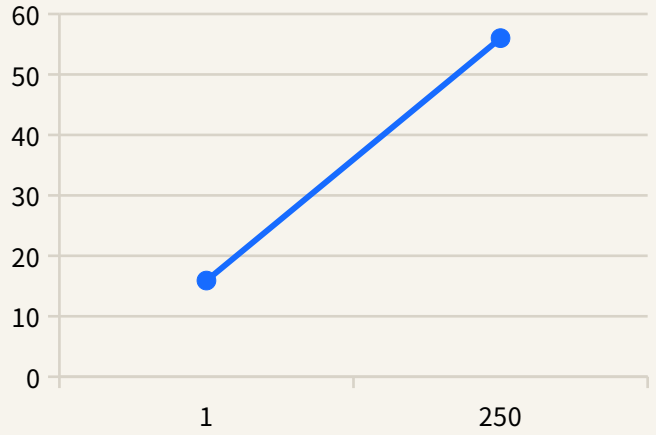
主要发现 1

采样次数提高覆盖率

除 Pythia 在 CodeContests 上始终为 0 外，论文测试的模型覆盖率普遍随采样预算上升。下图只使用正文明确报告的端点。

SWE-bench Lite

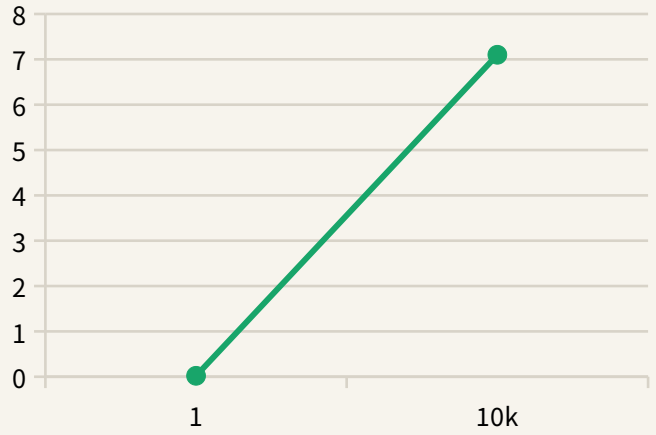
DeepSeek-Coder-V2 · k=1→250



15.9% → 56%

CodeContests

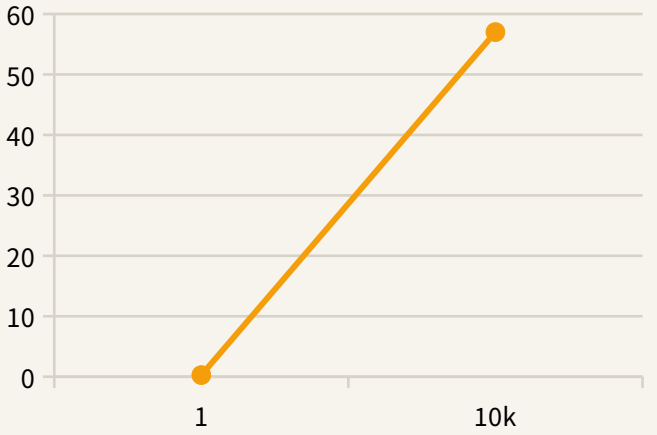
Gemma-2B · k=1→10k



0.02% → 7.1%

MATH

Pythia-160M · k=1→10k



0.27% → 57%

端点来自论文正文；连线仅表示方向，不补造中间实验值

边界： Pythia 在 CodeContests 上即使 k=10k ， coverage 仍为 0

主要发现 2

计算预算与成本

SWE-bench Lite • Moatless Tools

模型	单次成本	采样数	解决率	总成本
DeepSeek-Coder-V2	**$0.0072**	**5**	**29.6%**	**$10.8**
GPT-4o	$0.13	1	24.0%	$39
Claude 3.5 Sonnet	$0.17	1	26.7%	$51

五次 DeepSeek 的解决率更高，总成本仍不到 GPT-4o 的三分之一。

固定 FLOPs 下：最优模型随任务而变

MiniF2F / MATH / GSM8K

8B 模型 • 更多样本



更高采样吞吐

CodeContests

70B 模型 • 更少样本



更强单次能力

主要发现 3

推理时缩放律

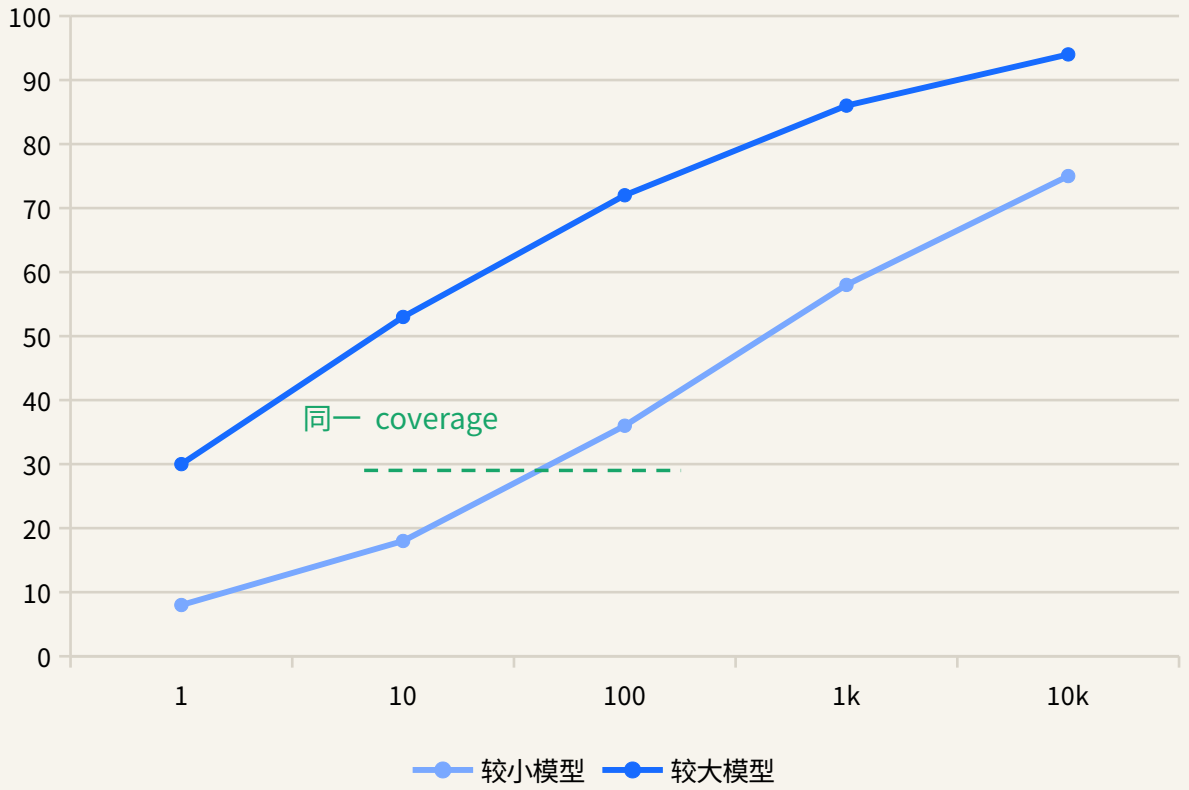
$$\log(c) \approx a \cdot k^b$$

等价于 $c \approx \exp(a \cdot k^b)$，拟合中 a、b 通常为负

论文发现： coverage 与样本数的关系经常可由指数化幂律近似。

它提供预算外推视角：增加多少采样，预计能换来多少覆盖率。

MiniF2F 偏差明显：这是经验拟合，不是普适定律

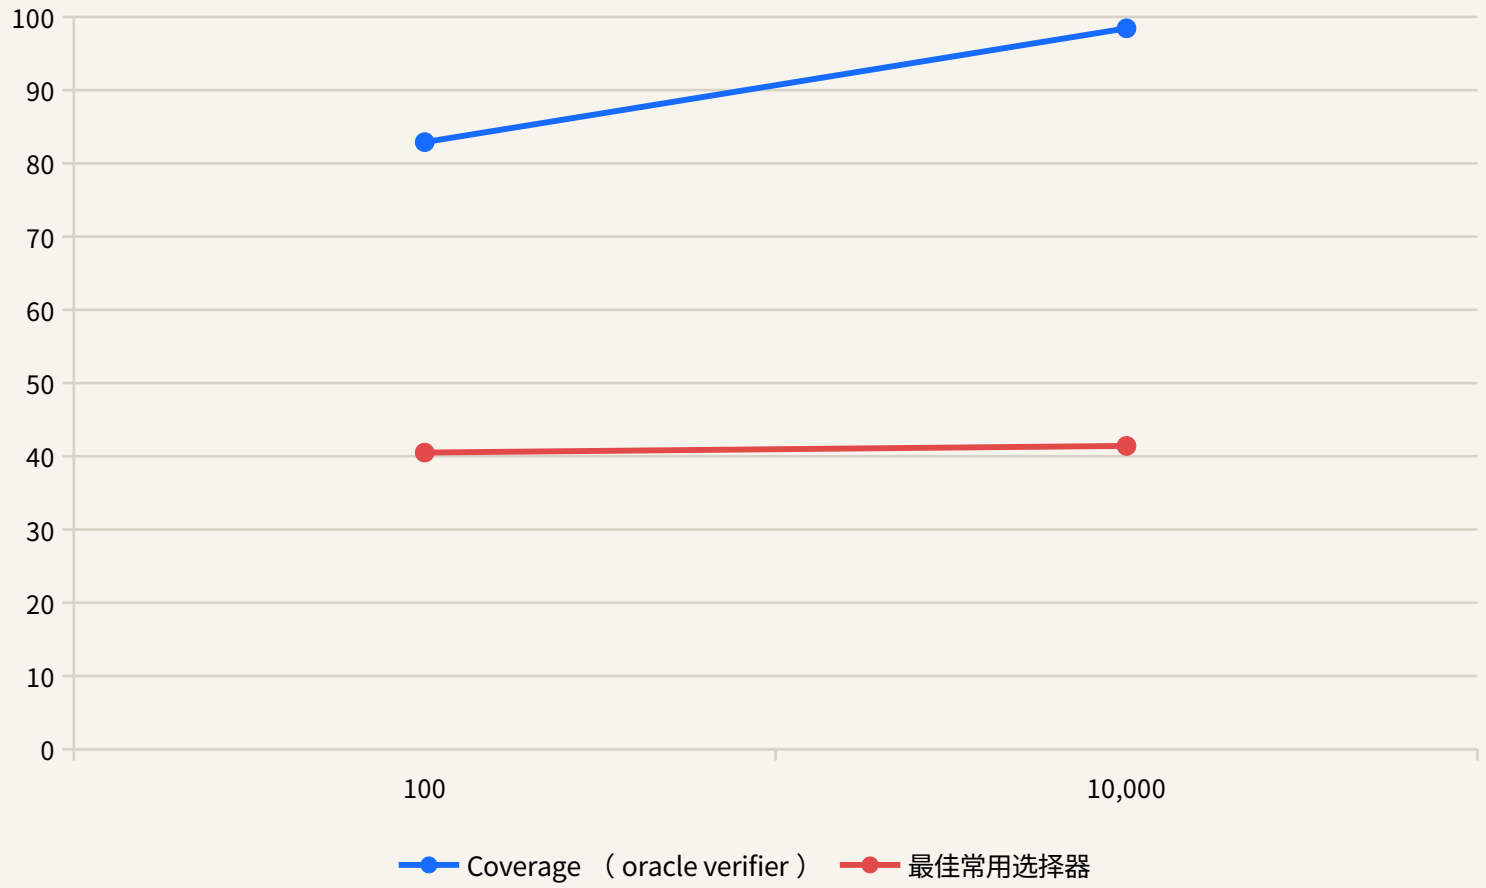


家族内曲线经水平平移后形状相似

右图为归一化示意，不是论文实验原始数据

主要发现 4

覆盖率增长，选择器却饱和



98.44%

10,000 个样本的 coverage

41.41%

最佳常用选择方法的成绩

正确答案越来越像“草堆里的针”

多数投票、奖励模型和加权投票都在约 100 个样本前后饱和。

实验细节

结果边界与研究影响

01

Flaky 测试

SWE-bench Lite 有 11.3% 的题测试不稳定。对被识别为 flaky 的题，候选解测试 11 次并多数表决。

02

测试集假阴性

CodeContests 的 122 道 Python 题中，35 道存在“官方正确解也通不过测试”的假阴性。

03

独立采样重复劳动

所有尝试使用相同提示与超参数且彼此隔离；多样性主要来自正温度采样。

验证器仍有可学信号

人工检查 105 条正确 CoT：超过 90% 的推理链忠实有效

重复采样扩展生成；能否转化为成绩取决于可扩展验证

Q&A

重复采样的结论

01

采样预算是一条独立的推理扩展轴

若正确解具有非零概率，更多独立尝试会提高 coverage；是否实用取决于概率与预算。

02

弱模型多采样有时更省成本

最优组合依赖任务、模型、总推理 FLOPs 、系统吞吐和验证成本。

03

验证器决定扩展能否落地

生成出正确答案，不等于能从候选集合中认出它。

论文

arxiv.org/abs/2407.21787

代码

github.com/ScalingIntelligence/large_language_monkeys

数据

huggingface.co/datasets/ScalingIntelligence/monkey_business

Figure 1 · 重复采样流程（复刻）

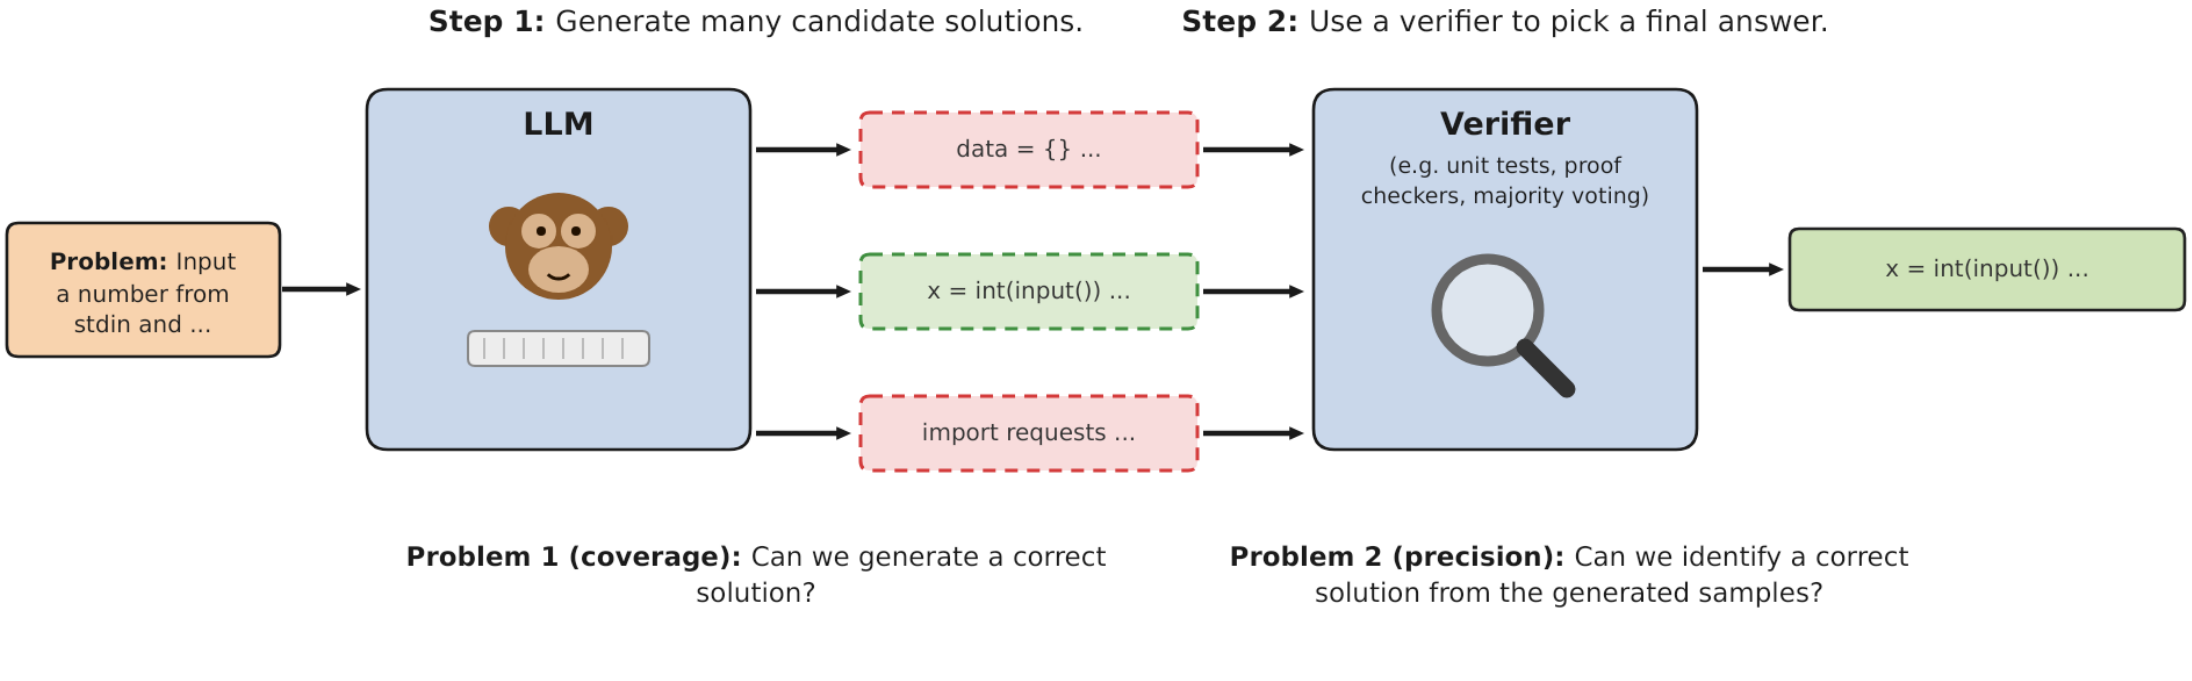


Figure 1 · 重复采样流程： LLM 并行生成多个候选解，验证器挑选最终答案，由此提出 coverage 与 precision 两个问题

Figure 2 · Coverage 随样本数缩放（复刻）

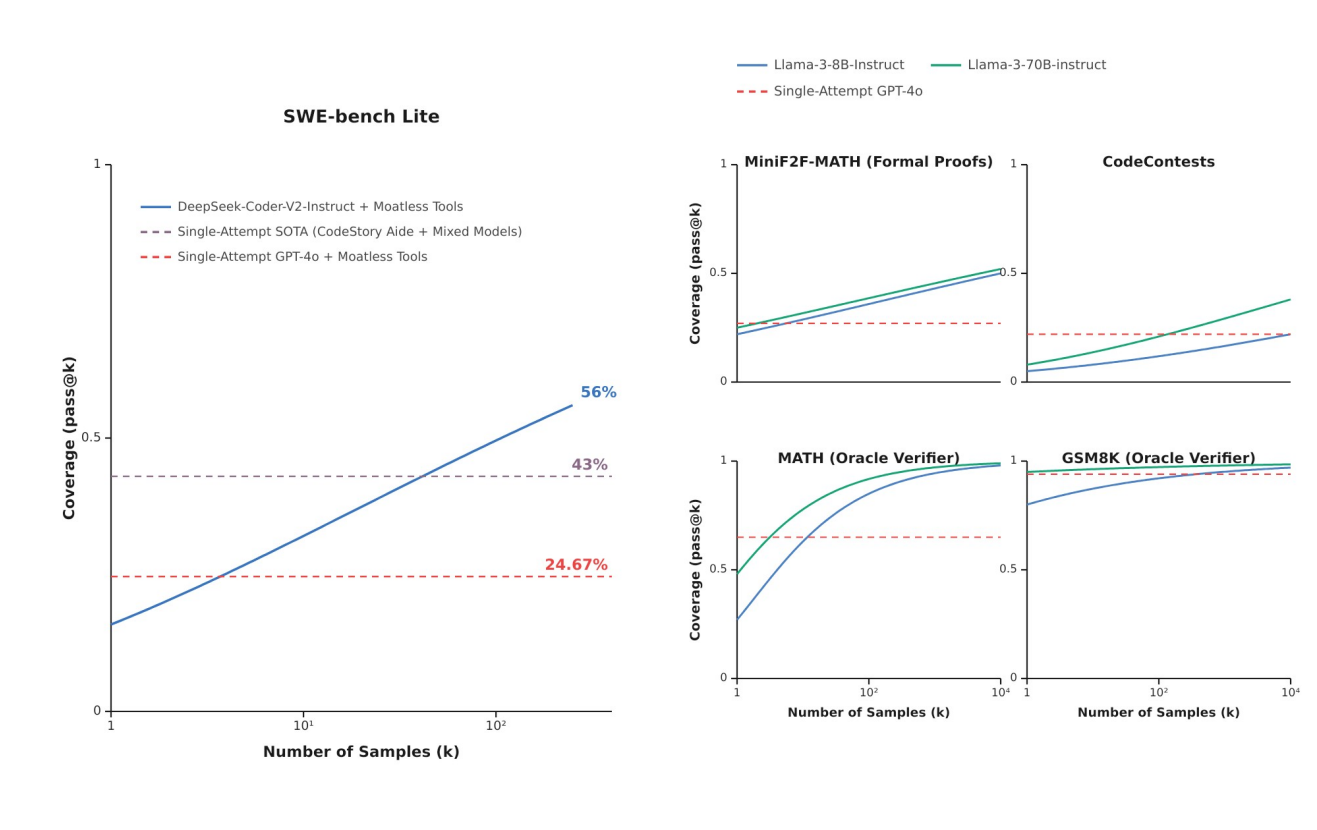


Figure 2 · Coverage (pass@k) 随样本数 k 平滑缩放： 8B-Instruct 在 MATH 上 k=250 时达 56%，超过单次采样的 70B-Instruct （43%）

Figure 3 · 13 个模型的 coverage 曲线（复刻）

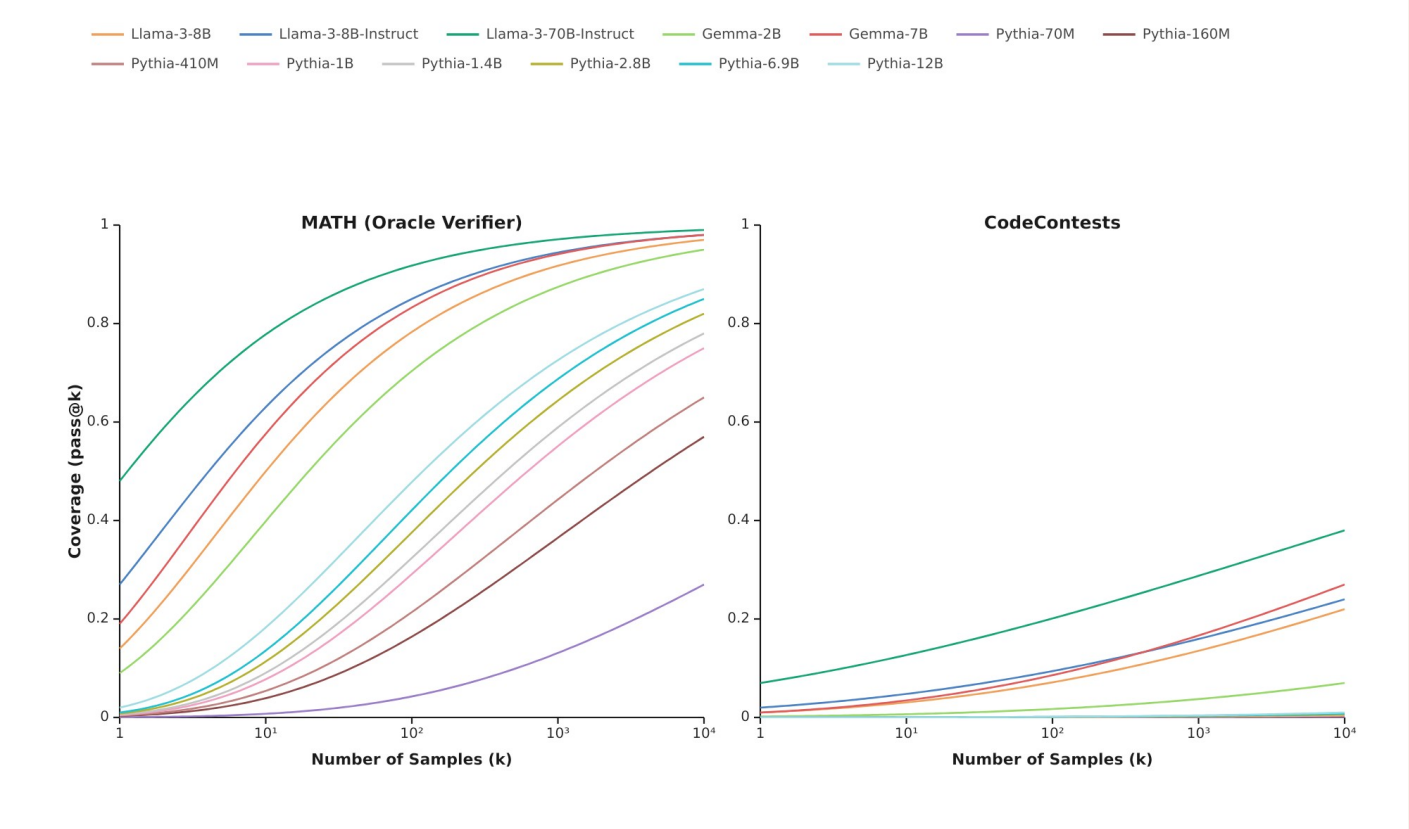
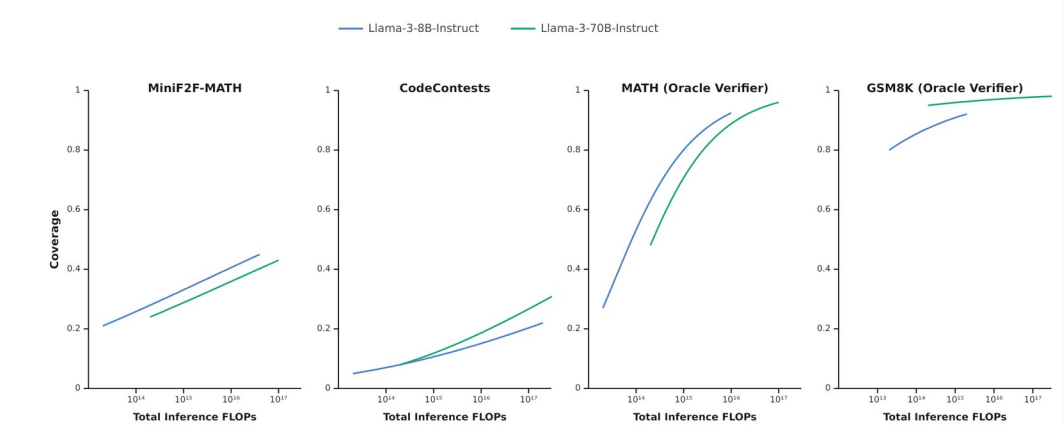


Figure 3 · 13 个模型在 MATH 与 CodeContests 上的 coverage 曲线：不同模型规模下 coverage 都随 k 持续改善

Figure 4 • Coverage 与推理 FLOPs （复刻）



Model	Cost per attempt (USD)	Number of attempts	Issues solved (%)	Total cost (USD)	Relative total cost
DeepSeek-Coder-V2-Instruct	0.0072	5	29.62	10.8	1x
GPT-4o	0.13	1	24.00	39	3.6x
Claude 3.5 Sonnet	0.17	1	26.70	51	4.7x

Figure 4 • 以总推理 FLOPs 衡量，小模型 + 更多采样可能更省： DeepSeek-Coder-V2-Lite-Instruct 采 5 次约 1x 成本，单次 GPT-4o 与 Claude 3.5 Sonnet 分别为 3.6x 与 4.7x

Figure 5 · Coverage 的幂律拟合（复刻）

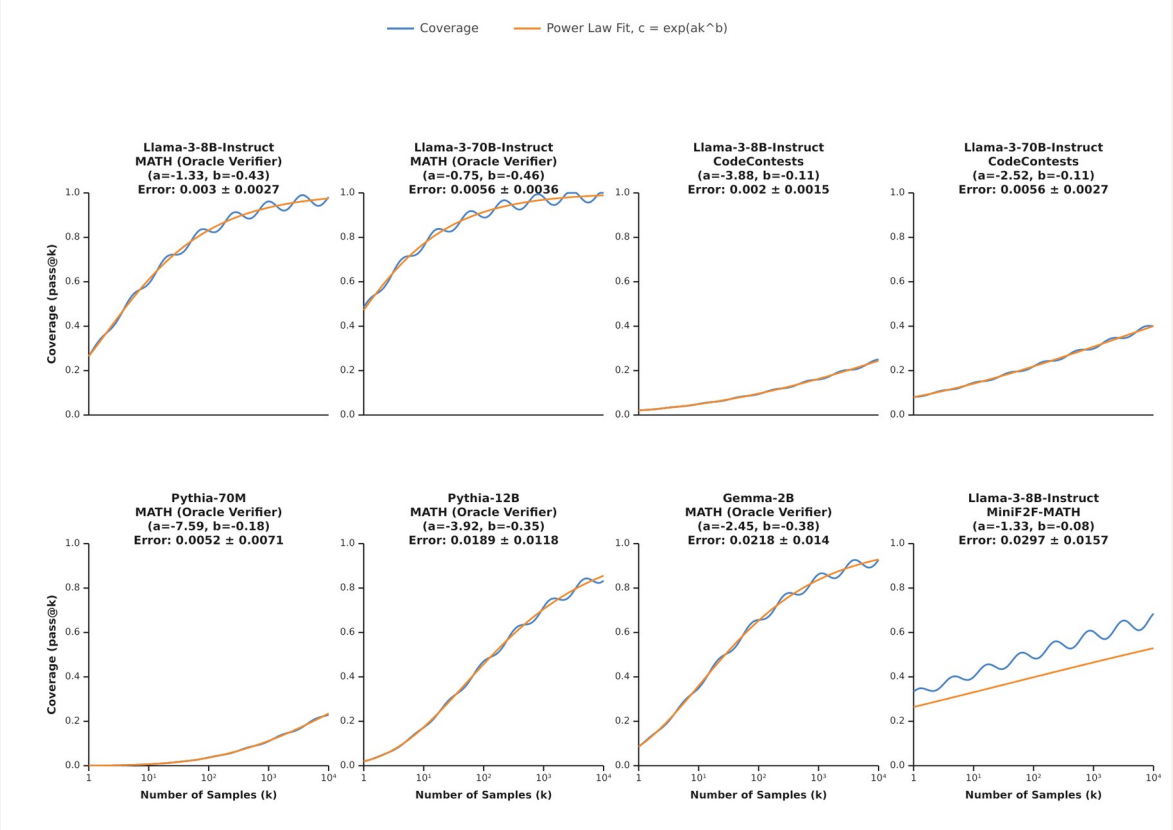


Figure 5 · 各模型与任务的 coverage 曲线均可用幂律 c = exp(a · k^b) 拟合，且拟合误差很小

Figure 6 · 归一化后的曲线坍缩（复刻）

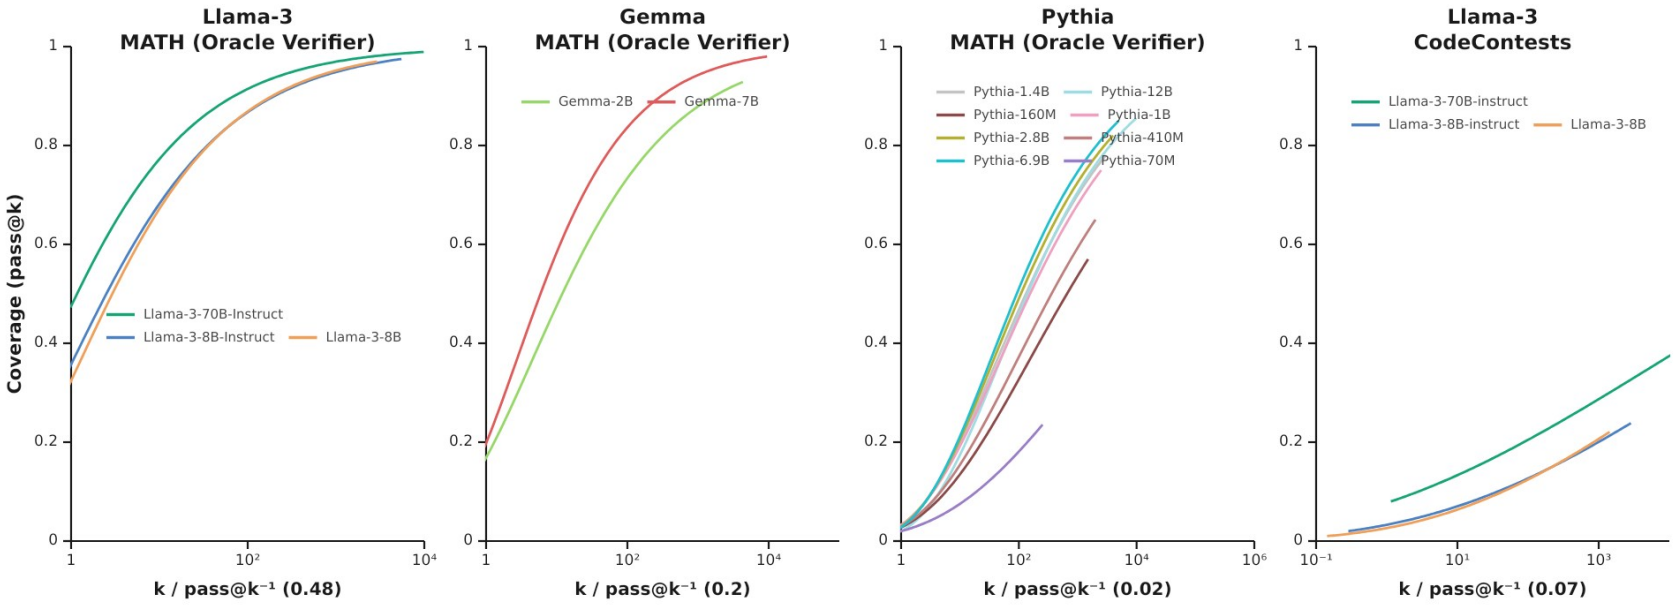


Figure 6 · 横轴按 k / pass@k^{-1}（即除以 pass@1）归一化后，同族模型的 coverage 曲线近似坍缩到一条曲线

Figure 7 · 选择策略对比（复刻）

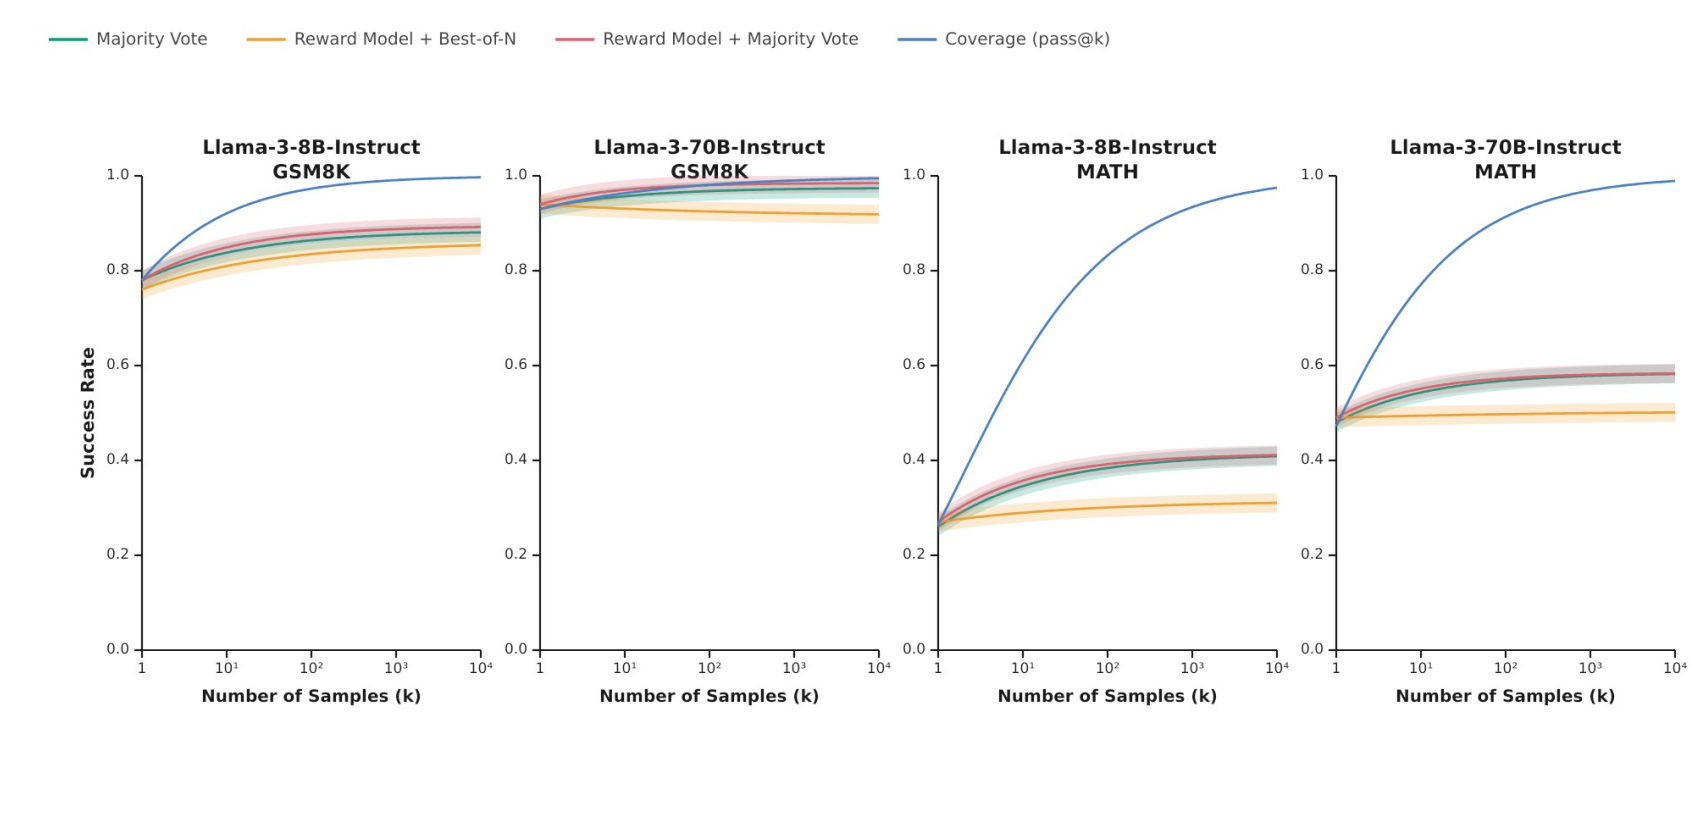


Figure 7 · 选择策略对比：多数投票持续优于 RM+Best-of-N，在多数投票上加 RM 增益有限；上限为 coverage (pass@k)

Figure 8 · 逐题可解性分布（复刻）

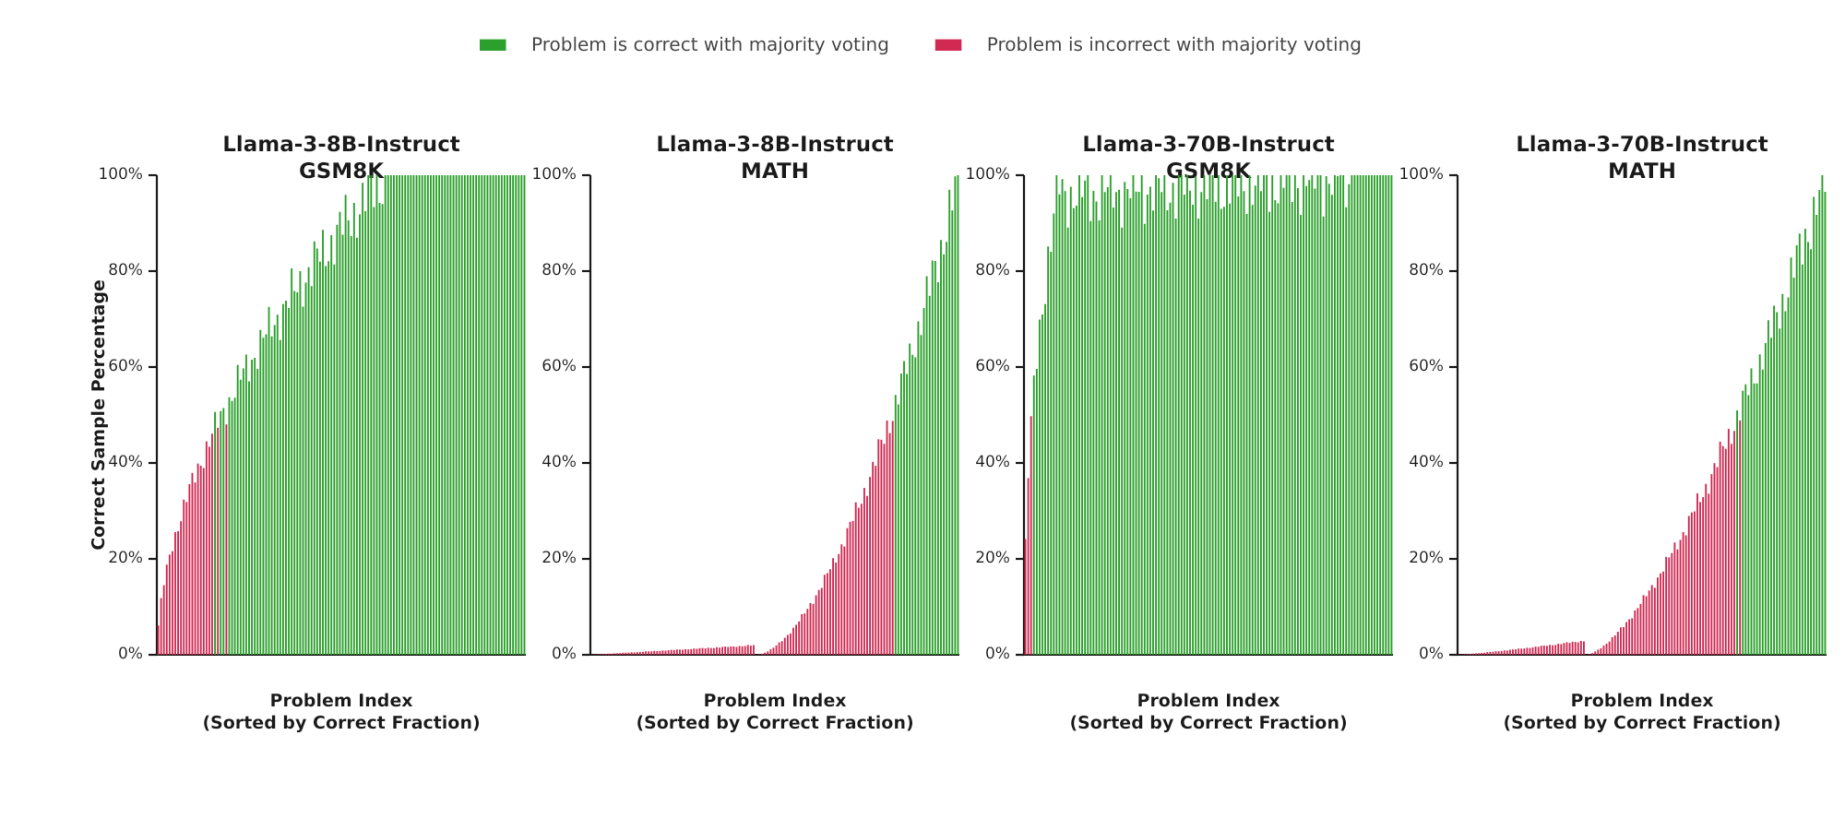


Figure 8 · 逐题正确样本比例（排序）：绿色 = 多数投票可解的题，红色 = 不可解；平均 coverage 高时仍有题目完全解不出